

حل مسئله چند هدفه

ستاره روشن

چکیده — در این گزارش به بررسی عملکرد چهار الگوریتم تکاملی بر روی مسئله یافتن ترتیب کودها با ماکزیمم دسترس پذیری همچنین ماکزیمم بهروری.

۱. پیش پردازش ها

در ابتدا دیتاستی را که در task چهارم بدست آورده بودیم فراخوانی می کنیم. سپس در آرایه قرار داده و روی اسامی کودها و کشورها factorize انجام می دهیم.

```
! = pd.read_excel(r"C:\Users\mcf\OneDrive\Desktop\Availability (1).xlsx")
uples = np.asarray(df)
:
```

country	Fertilizers	Import&Product	Export	Availability	Use	x
Brazil	Ammonia, anhydrous	24144572.05	399156.28	23745415.77	2571549.00	5931.614778
Brazil	Ammonium nitrate (AN)	21546416.92	214625.65	21331791.27	13821890.37	31882.001541
Brazil	Ammonium sulphate	30988444.53	53840.25	30934604.28	22805149.59	52603.066217
Brazil	Calcium ammonium nitrate (CAN) and other mixtu...	2020987.02	10844.03	2010142.99	1164236.84	2685.464848
Brazil	Diammonium phosphate (DAP)	6948831.81	148854.13	6799977.68	4846157.53	11178.297447
...
Mexico	Sodium nitrate	32779.02	1030.91	31748.11	0.00	0.000000
Mexico	Superphosphates above 35%	622825.23	2467787.77	-1844962.54	811919.38	1699.959390
Mexico	Superphosphates, other	0.00	0.00	0.00	21682383.00	45397.574551
Mexico	Urea	21917270.86	303460.75	21613810.11	8931655.72	18700.689238
Mexico	Urea and ammonium nitrate solutions (UAN)	1028338.92	46263.77	982075.15	305737.70	640.139510

شکل ۱ فراخوانی دیتاست.

در گام بعد هر کروموزوم بصورت زیر خواهد بود که شامل ۲۳ ژن می باشد. کود در آلل (allel) شماره ۰، کودی با بیشترین اهمیت از نظر دسترس پذیری و بهروری خواهد بود. اگر کشوری شامل کودی نباشد در محاسبه fitness کود محاسبه نخواهد شد. کروموزوم زیر کروموزومی فرضی است که در آن کود شماره یک دارای بیشترین اهمیت و کود شماره ۲۳ دارای کمترین اهمیت است.

کود شماره	کود شماره	...	کود شماره	کود شماره	کود شماره
یکست و سه	دو		چهار	سه	دو

۲. تعریف مسئله

در این بخش ما به تعریف مسئله خواهیم پرداخت. در pymoo نیاز است که تعداد متغیرها، اهداف و حد بالا و پایین متغیرها تعریف شود. در این قسمت با استفاده از تابع super این کار انجام شده که برای تمام الگوریتم های ثابت است در این مسئله خاص. مسئله ما دارای ۲۳ متغیر (خط ۴)، دو هدف (خط ۵)، بدون قید (خط ۶)، و کران پایین ۰ و کران بالای ۲۳ برای هر متغیر (خط ۷ و ۸) است. سپس قسمت evaluate خواهد بود که شامل مینیم کردن

دو هدف f_1 و f_2 است (مسئله اصلی ماکزیمم کردن این دو که با ضرب یک منفی با مینیمم کردن در واقع ماکزیمم را بدست می آوریم). برای هر کشور چک می شود و اهمیت هر کود با توجه به مکانی که قرار دارد با مقادیر قبل جمع می شود. باید خاطر نشان کرد که در این کتابخانه اول تمامی جمعیت به این تابع داده می شود پس نیاز است آرایه ای به اندازه تعداد جمعیت برای f_1 و f_2 در نظر گرفته بشود (خط ۱۱ و ۱۲). در آخر f_1 (دسترس پذیری) و f_2 (بهروری) در آرایه خط ۲۳ کنار هم به ازای هر عضو جمعیت قرار می گیرند.

```
class MyProblem(Problem):
    def __init__(self):
        super().__init__(n_var=23,
                           n_obj=2,
                           n_constr=0,
                           xl=np.zeros(23),
                           xu=np.array([23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23,23]))

    def _evaluate(self, X, out, *args, **kwargs):
        f1 = np.zeros(X.shape[0])
        f2 = np.zeros(X.shape[0])
        # print(X.shape)
        for p in range(X.shape[0]):
            for i in range(23):
                temp = X[p,i]
                for j in range(115):
                    if samples[j,i] == 4 and samples[j,1] == X[p,i]:
                        f1[p] += -(samples[j,4] * (23 - i))
                        f2[p] += -(samples[j,6] * (23 - i))

        out["F1"] = np.column_stack([f1, f2])
        #out["G"] = np.column_stack([0,0])
```

شکل ب. تعریف مسئله

۳. الگوریتم ها

این قسمت بسیار ساده و صریح است. تنها نیاز است الگوریتم فراخوانی و import شود (شکل ت). با الگوریتم NSGA۲ آغاز می کنیم نیاز است از Myproblem در بخش قبل یک شی ساخته شود (خط ۱). در خط دوم مقادیری به الگوریتم داده به ترتیب، اندازه جمعیت (برابر ۱۰۰)، نوع representation (در اینجا permutation که اول بصورت رندوم)، سپس crossover (در اینجا تغییر order)، سپس جهش (در این جا برعکس کردن).

جدول ۱. پارامترهای مورد استفاده

Representation	Permutation
crossover	Order
mutation	Inverse
Population size	۱۰۰
Initial population	Random
Termination	۵۰۰ generation


```

1 from pymoo.algorithms.nsga3 import NSGA3
2 ref_energy = get_reference_directions("energy", 2, 100, seed=1)
3 algorithm_energy = NSGA3(pop_size=100, sampling=get_sampling("perm_random"),
4 crossover=get_crossover("perm_ox"),
5 mutation=get_mutation("perm_inv"),
6 eliminate_duplicates=True,
7 ref_dirs=ref_energy,
8 normalization="front")
9 res_NSGA3_energy = minimize(problem, algorithm_energy, Termination = ("n_gen", 200),
10 | seed = 1, verbose = False, save_history=True)
11 plot = Scatter()
12 plot.add(problem.pareto_front(), plot_type="line", color="black", alpha=0.7)
13 plot.add(res_NSGA3_energy.F, color="lightblue")
14 plot.show()

```

شکل خ. فراخوانی الگوریتم NSGA^۳

در شکل زیر pareto front این الگوریتم دیده می‌شود.



شکل د. نمودار pareto front برای NSGA^۳ (محور عمودی بهروری و محور افقی دسترس پذیری)

در آخر به الگوریتم UNSGA^۳ می‌پردازیم. پارامترها شبیه به جدول ۳ استفاده شده‌اند. و reference direction نیز در خط ۲ تعریف شده است.


```

1 from pymoo.algorithms.unsga3 import UNSGA3
2 ref_energy = get_reference_directions("energy", 2, 100, seed=1)
3 algorithm = UNSGA3(pop_size=100, sampling=get_sampling("perm_random"),
4 crossover=get_crossover("perm_ox"),
5 mutation=get_mutation("perm_inv"),
6 eliminate_duplicates=True,
7 ref_dirs=ref_energy,
8 normalization="front")
9 res_UNSGA3_energy = minimize(problem, algorithm, Termination = ("n_gen", 200),
10 | seed = 1, verbose = False, save_history=True)
11 plot = Scatter()
12 plot.add(problem.pareto_front(), plot_type="line", color="black", alpha=0.7)
13 plot.add(res_UNSGA3_energy.F, color="pink")
14 plot.show()

```

شکل ذ. الگوریتم UNSGA^۳

و pareto front در شکل زیر آمده است.



شکل ر. نمودار pareto front برای RNSGA^۲ (محور عمودی f^۲ و محور افقی f^۱)

لازم به ذکر است در قسمت ۵ پیوست مقایسه reference pointها آمده است.


```

1 problem = MyProblem()
2 algorithm = NSGA2(pop_size=100, sampling=get_sampling("perm_random"),
3 crossover=get_crossover("perm_ox"),
4 mutation=get_mutation("perm_inv"),
5 eliminate_duplicates=True)
6 res = minimize(problem, algorithm, Termination = ("n_gen", 500), seed = 1, verbose = False)
7 plot = Scatter()
8 plot.add(problem.pareto_front(), plot_type="line", color="black", alpha=0.7)
9 plot.add(res.F, color="red")
10 plot.show()

```

شکل ت. فراخوانی الگوریتم NSGA^۲

نتایج در خط ۶ ذخیره می‌شود. خطوط ۷، ۸، ۹ و ۱۰ نمودار pareto front را برای ما رسم خواهند کرد (شکل ث).



شکل ث. نمودار pareto front برای NSGA^۲ (محور عمودی بهروری و محور افقی دسترس پذیری)


حال به بررسی الگوریتم RNSGA^۲ می‌پردازیم. پارامترها شبیه به جدول ۳ استفاده خواهد شد تنها اینجا ref points با مقادیر قابل مشاهده در خط ۳ و همچنین مقدار اپسیلون به پیشنهاد خود مقاله ۰.۰۱ انتخاب شده. نتیجه pareto front در شکل ج مشاهده می‌کنید.

```

1 from pymoo.algorithms.rnsa2 import RNSGA2
2
3 ref_energy = get_reference_directions("energy", 2, 100, seed=1)
4 algorithm_energy = RNSGA2(pop_size=100, sampling=get_sampling("perm_random"),
5 crossover=get_crossover("perm_ox"),
6 mutation=get_mutation("perm_inv"),
7 eliminate_duplicates=True,
8 ref_points = ref_energy, epsilon=0.01,
9 normalization="front")
10 res_RNSGA2_energy = minimize(problem, algorithm_energy, Termination = ("n_gen", 200),
11 | seed = 1, verbose = False, save_history=True)
12 plot = Scatter()
13 plot.add(problem.pareto_front(), plot_type="line", color="black", alpha=0.7)
14 plot.add(res_RNSGA2_energy.F, color="Orange")
15 plot.show()

```

شکل ج. الگوریتم RNSGA^۲




شکل ح. نمودار pareto front برای RNSGA^۲ (محور عمودی بهروری و محور افقی دسترس پذیری)

الگوریتم بعدی NSGA^۳ است. اینجا باید به ۱۰۰ reference direction داشته باشیم (خط ۲) و بقیه پارامترها مشابه جدول ۳ آمده است.


۴. نتیجه گیری

در این قسمت با مقایسه pareto front الگوریتم‌ها متوجه می‌توان شد که تمامی الگوریتم‌ها تقریباً یک pareto front داشتند بطور کل RNSGA^۲ عملکرد بدتری داشت.



شکل ز. مقایسه pareto front الگوریتم‌ها. (محور عمودی f_2 و محور افقی f_1) همچنین رنگ نتایج مربوط به هر الگوریتم در راهنمای بالای شکل مشخص شده است.

همچنین از لحاظ همگرایی الگوریتم‌ها بصورت شکل زیر می‌باشند. که همگرایی RNSGA^۲ از همه بهتر است.



شکل س. مقایسه همگرایی الگوریتم‌ها. محور افقی نمایانگر تعداد نسل‌ها و نمودار عمودی نمایانگر هدف است.


۵. پیوست

در این بخش به بررسی reference point ها می‌پردازیم. از دو نوع reference point استفاده می‌کنیم یکی das-dennis و دیگری energy که دومی را خود کتابخانه pymoo توصیه کرده بود در تمامی نتایج در قسمت‌های قبل از energy استفاده شده است.


```
1 from pymoo.algorithms.rnsga2 import RNSGA2
2 from pymoo.factory import get_visualization, get_reference_directions
3 from pymoo.util.ref_dirs.energy import RieszEnergyReferenceDirectionFactory
4
5 ref_dennis = get_reference_directions("das-dennis", 2, n_points=5, seed=1)
6 ref_energy = get_reference_directions("energy", 2, 8, seed=1)
7
8 algorithm_energy = RNSGA2(pop_size=100, sampling=get_sampling("perm_random"),
9 crossover=get_crossover("perm_ox"),
10 mutation=get_mutation("perm_inv"),
11 eliminate_duplicates=True,
12 ref_points = ref_energy, epsilon=0.01,
13 normalization='front')
14 res_RNSGA2_energy = minimize(problem, algorithm_energy, Termination = ("n_gen", 200), seed = 1, verbose = 2)
15 algorithm_dennis = RNSGA2(pop_size=100, sampling=get_sampling("perm_random"),
16 crossover=get_crossover("perm_ox"),
17 mutation=get_mutation("perm_inv"),
18 eliminate_duplicates=True,
19 ref_points = ref_dennis, epsilon=0.01,
20 normalization='front')
21
22 res_RNSGA2_dennis = minimize(problem, algorithm_dennis, Termination = ("n_gen", 200), seed = 1, verbose = 2)
23
24 plot = Scatter()
25 plot.add(problem.pareto_front(), plot_type="line", color="black", alpha=0.7)
26 plot.add(res_RNSGA2_energy.F, color="Orange")
27 plot.add(res_RNSGA2_dennis.F, color="black")
28 plot.show()
```

شکل ش. به عنوان نمونه نحوه result گرفتن برای مقایسه به این صورت است از هردو روش به تفکیک نتیجه گرفته شده و روی یک نمودار رسم میکنیم.

در ادامه مشاهده می‌شود که برای energy رنگ نارنجی و برای dennis رنگ مشکی انتخاب شده است و چون رنگ مشکی بعدتر رسم شده و دقیقاً نقاط یکی هستند بنابراین در شکل تنها مشکی قابل مشاهده است. الگوریتم RNSGA^۲ تفاوتی میان این دو روش نیست.




شکل ص. Pareto front برای RNSGA^۲ که با ۵ پارتیشن برای dennis و ۸ برای energy. و محورهای افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند.




شکل ض. Pareto front برای RNSGA^۲ که با ۹۰ پارتیشن برای dennis و ۹۰ برای energy. و محورهای افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند.

با توجه به اشکال بالا نه تعداد پارتیشن‌ها و نه نوع reference point گرفتن روی Pareto front تاثیر نداشته است.




شکل ع. Pareto front برای NSGA^۳ که با ۹۰ پارتیشن برای dennis و ۹۰ برای energy. و محوره‌های افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند. قهوه‌ای نشان دهنده dennis و صورتی نشان دهنده energy است.




شکل غ. Pareto front برای NSGA^۳ که با ۵ پارتیشن برای dennis و ۸ برای energy. و محوره‌های افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند. قهوه‌ای نشان دهنده dennis و صورتی نشان دهنده energy است.

در حالت کلی تفاوت چشمگیری بین دو روش مشاهده نمی‌شد. در نتایج همانطور که قبلاً ذکر شده است از روش energy و با تعداد نقاط ۹۰ استفاده شده است در فضای ۲ بعدی.

در NSGA^۳ اما با کم شدن تعداد پارتیشن تعداد نقاط کم می‌شد. می‌توان گفت تعداد نقاط بیشتر بهتر است چون set جوابهای قابل قبول ما بیشتر است اما دو روش تفاوتی چشمگیری باهم ندارند.



شکل ط. Pareto front برای NSGA^۳ که با ۹۰ پارتیشن برای dennis و ۹۰ برای energy. و محوره‌های افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند. آبی پر رنگ نشان دهنده dennis و کم رنگ نشان دهنده energy است.



شکل ظ. Pareto front برای NSGA^۳ که با ۵ پارتیشن برای dennis و ۸ برای energy. و محوره‌های افقی و عمودی نیز به ترتیب f_1 و f_2 را نشان می‌دهند. آبی پر رنگ نشان دهنده dennis و کم رنگ نشان دهنده energy است.

در NSGA^۳ نیز به همین منوال است. یعنی تعداد اعضای Pareto front ما وابسته به تعداد پارتیشن‌ها است و اما دو روش dennis و energy تفاوت چشمگیری با یکدیگر ندارند. اما در اینجا به نظر کمی dennis که با رنگ قهوه‌ای نمایش داده شده بهتر است.